Bigram and Trigram Computing

Paolo Le Piane
Manuel Natale Sapia

Obiettivo

- Implementazione di un generatore di bigrammi e trigrammi di lettere estratti da un testo selezionato

Svolgimento

- Tre versioni di implementazione:
  - versione sequenziale in Java
  - versione parallela in Java
  - versione parallela in C++ con OpenMP
- Risultati e analisi:
  - analisi speed up
  - analisi tempi di esecuzione

Dataset:

- Testo del romanzo ‘’Orgoglio e Pregiudizio’’ modificato per ottenere dimensioni diverse utili per l’analisi, in particolare: 75 Kb, 150 Kb, 250 Kb, 500 Kb, 1 Mb, 2 Mb, 4 Mb, 8 Mb, 16 Mb, 32 Mb, 64 Mb.

Specifiche PC utilizzato:

- Processore Intel Core i7-6700HQ da 2.60GHz con turbo boost fino a 3.5GHz
- GPU NVIDIA GeForce GTX 970M con 1280 core e 3GB di memoria dedicata
- 16GB di memoria RAM

Versione Sequenziale in Java

Funzioni implementate:

- myReadFile()
- generateNgrams()
- frequency()
- myWriteFile()
- main()

```
public static String myReadFile(String filename) {
try {
BufferedReader reader = new BufferedReader(new
FileReader(filename));
StringBuilder output = new StringBuilder();
String line;
while ((line = reader.readLine()) != null) {
  ...
}
reader.close();
return output.toString().toLowerCase();
...
```

- *generateNgrams()* percorre la stringa di testo e crea gli n-grammi in base all'n scelto.

```
public static List<String> generateNgrams(int n, String str) {
        String letters = "abcdefghijklmnopqrstuvwxyz";
        boolean skip;
        List<String> ngrams = new ArrayList<>();
        for (int i = 0; i < str.length() - n + 1; i++) {
            skip = false;
            for (int k = 0; k < n ; k++) {
                if (letters.indexOf(str.charAt(i+k)) == -1) {
                    skip = true;
                    break;
                }
            }
            if (skip) continue;
            ngrams.add(str.substring(i, i + n));
        }
        return ngrams;
    }
```

Versione Parallela in Java

- Implementazione in Java utilizzando l'interfaccia Callable.
- Funzione *create_chunks()* per ottenere gli intervalli per partizionare in blocchi la stringa con il testo.

```
public static List<Integer> create_chunks(int numb_th,
String str) {
        List<Integer> result = new ArrayList<>();
        int pos;
        result.add(0);
        int chunk = str.length() / numb_th;
        for (int k = 1; k < numb_th; k++ ) {
            pos = chunk * k;
            while (str.charAt(pos) != ' ') {
                pos += 1;
            }
            result.add(pos);
        }
        result.add(str.length());
        return result;
    }
```

- Creazione di un ThreadPoolExectuor che genera e gestisce un threadPool.
- *call()* esegue il task asincrono e genera gli n-grammi relativi all'intervallo del testo selezionato.

```
public static void main(String[] Args) throws
InterruptedException {
        ...
        ThreadPoolExecutor executor = (ThreadPoolExecutor)
Executors.newFixedThreadPool(4);
        List<Future<List<String>>> resultList = new
ArrayList<>();
        Instant start_t = Instant.now();
        for (int i = 0; i < number_th; i++) {
            CallMain prova = new CallMain(2, book, ck.get(i),
ck.get(i+1));
            Future<List<String>> result = executor.submit(prova);
            resultList.add(result);
        }
        for (Future<List<String>> future : resultList) {
            try
            {
                count = count + future.get().size();
            }
            ...
```

Versione Parallela in C++ OpenMP

- Modello fork&join in OpenMP
- Metodi *myReadFile()* e *myWriteFile()* per la lettura da file e la scrittura su file.

```
regex letter("[^[:alpha:]]");
//apertura file
while (getline(inputFile, line)) {
	line = regex_replace(line, letter, " ");
	stringstream line2(line)
	while (getline(line2, word, ' ')) {
	//rendi word minuscolo e inseriscilo nel vettore
di stringhe
	}
}
```

- Metodo per la creazione dei thread *generateNgramsParallel()* *dove si usano i costrutti di OpenMP*
- Vettore *ngrams* multidimensionale.
- Variabile *thread_index* fondamentale per il metodo *compute()*
- Per ogni parola genera $m - n + 1$ n-grammi.
- Metodo *frequency().*

```
#pragma omp parallel private(thread_index,word)
num_threads(num_threads)
{
     thread_index = omp_get_thread_num();
     #pragma omp for
     for (int j = 0; j <strList.size(); j++) {
          word = strList[j];
          compute(thread_index, word, n, ngrams);
     }
}
```

```
if(!word.empty())
        limit = word.length() - n + 1;
        for(int i = 0; i < limit; i++){
            ngrams[thread_index].push_back(word.sub
str(i,n));
        }
```

Confronto Speedup in Java

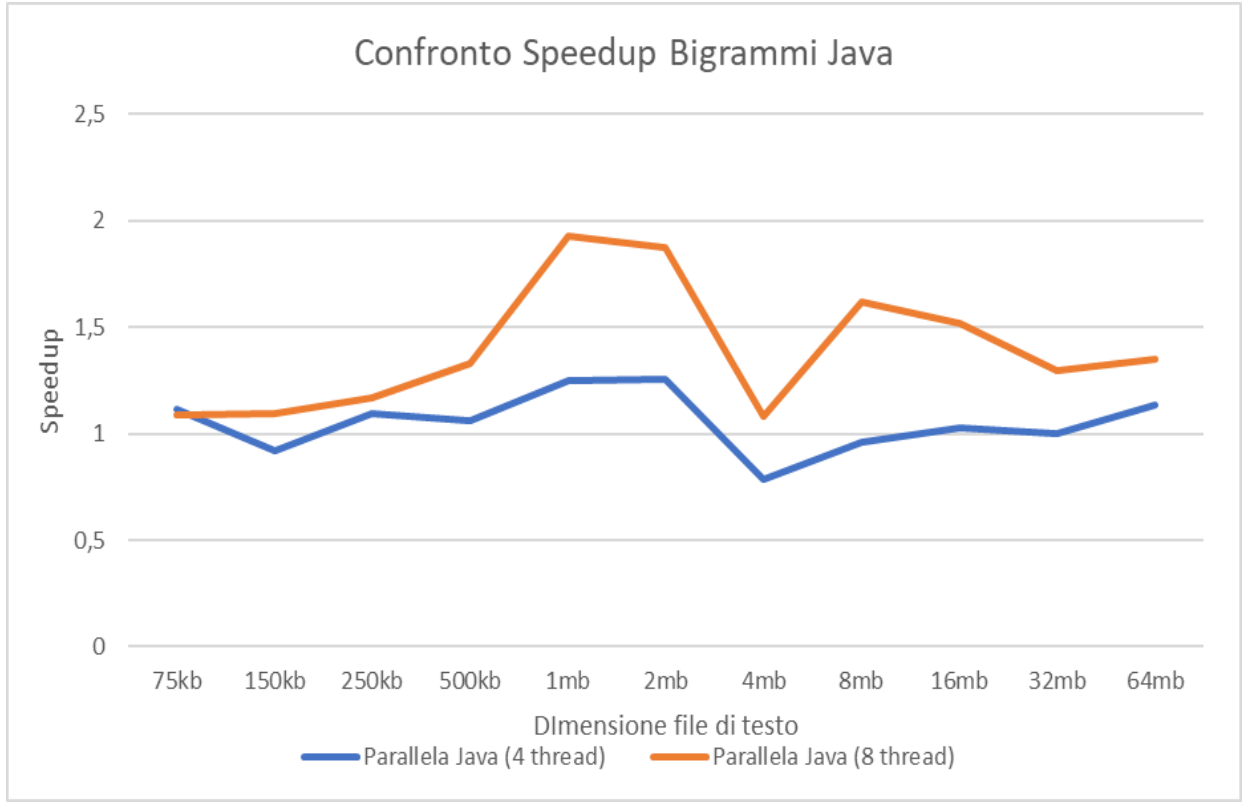

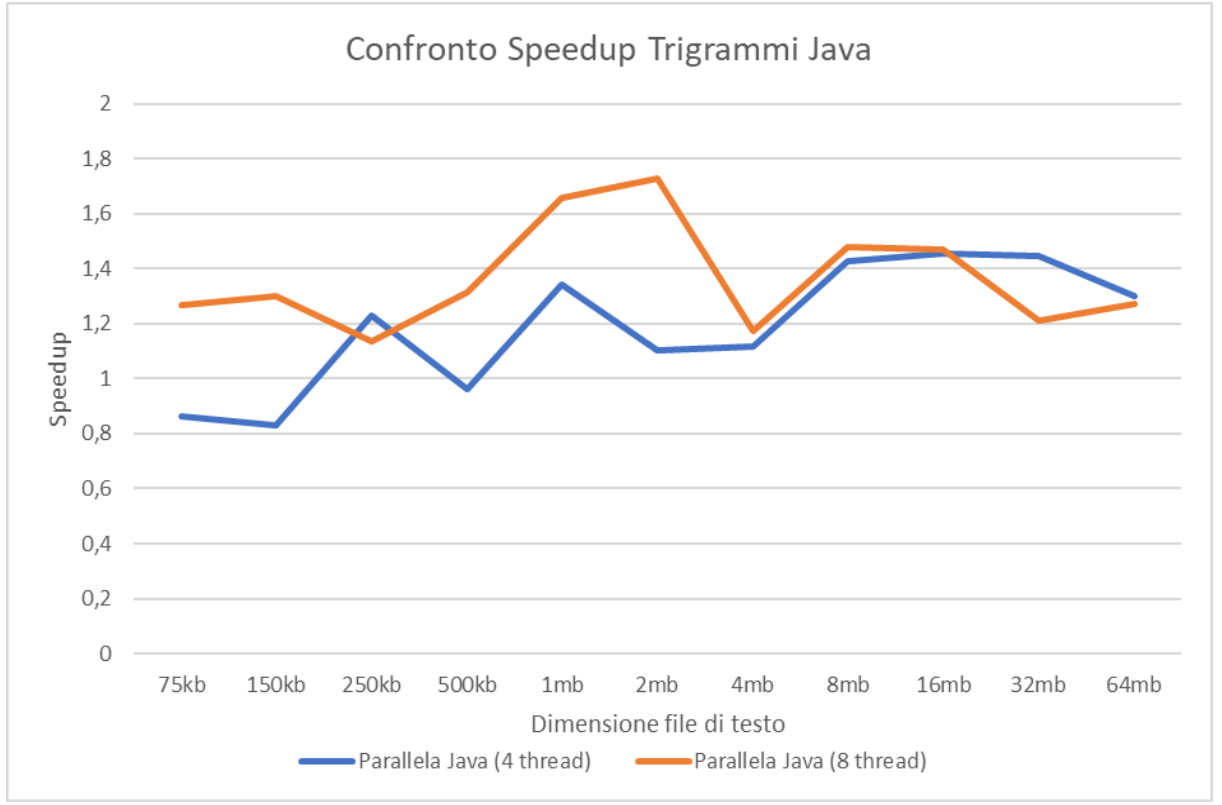

Confronto Speedup in C++ (OpenMP)

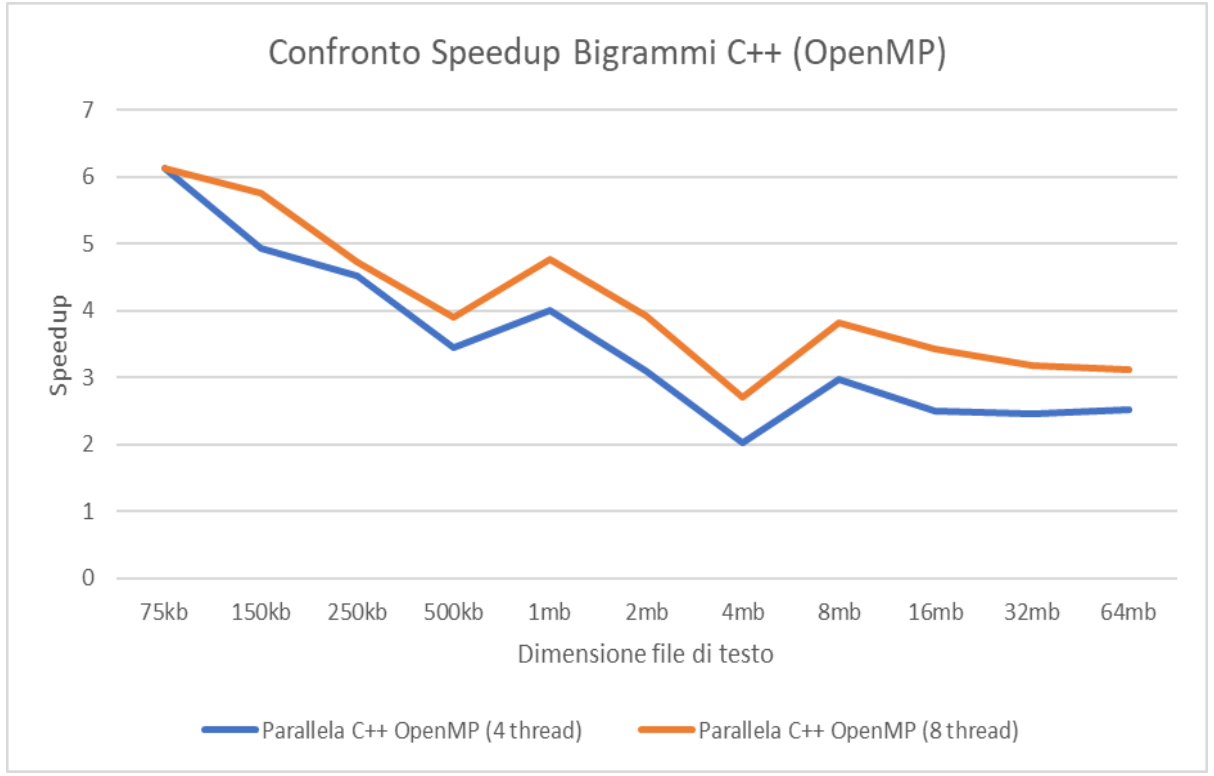

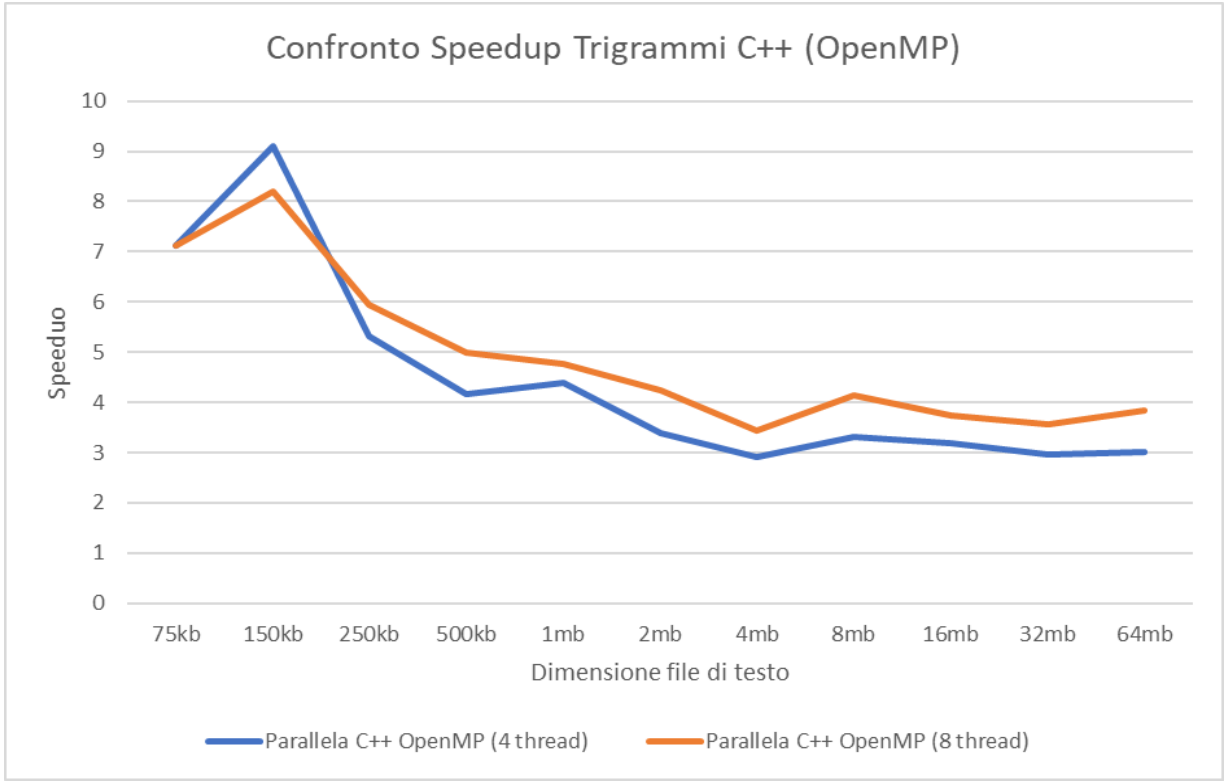

Confronto tempi di esecuzione in Java

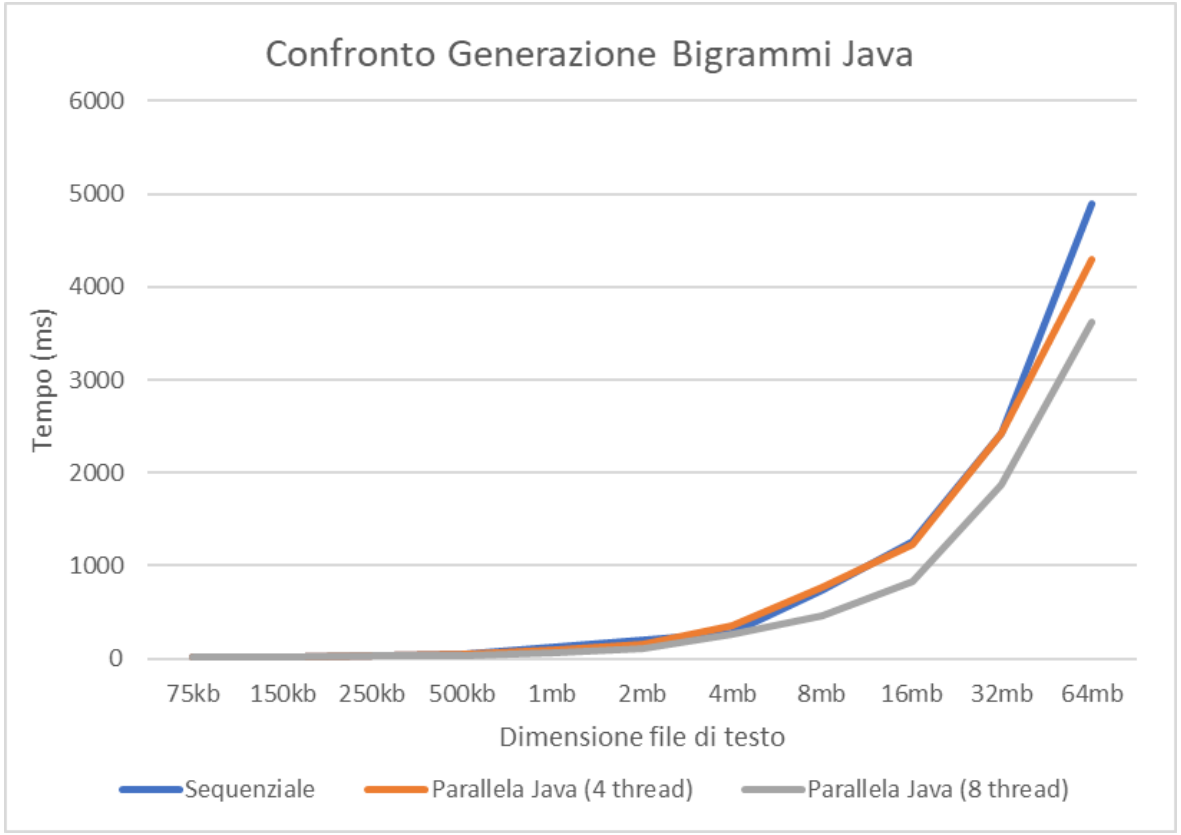

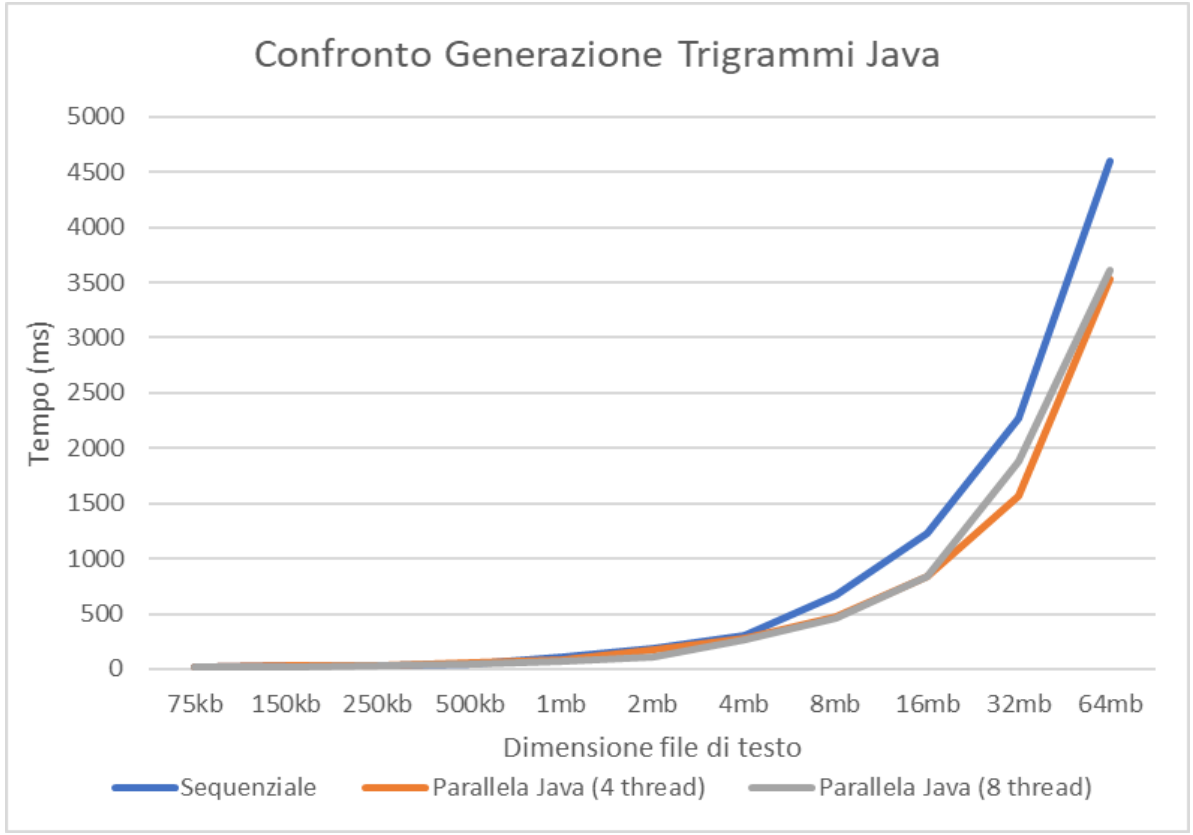

Confronto tempi di esecuzione in C++ (OpenMP)

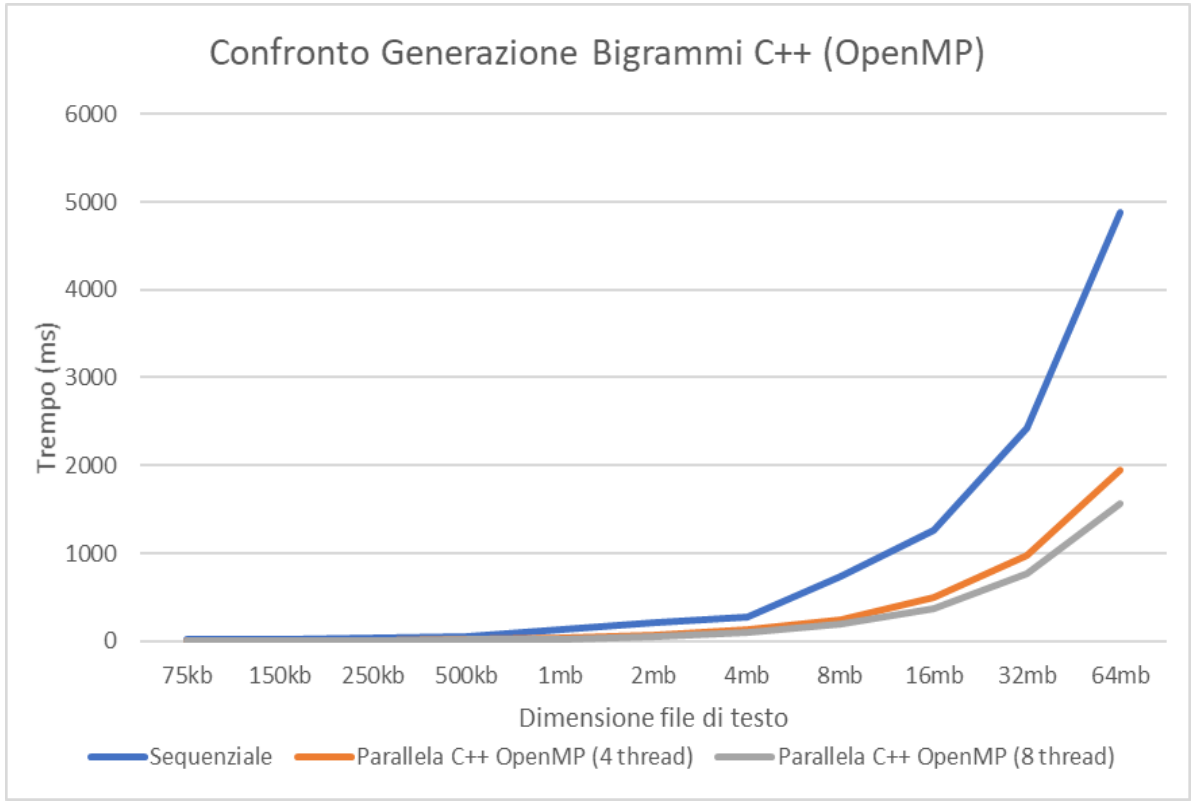

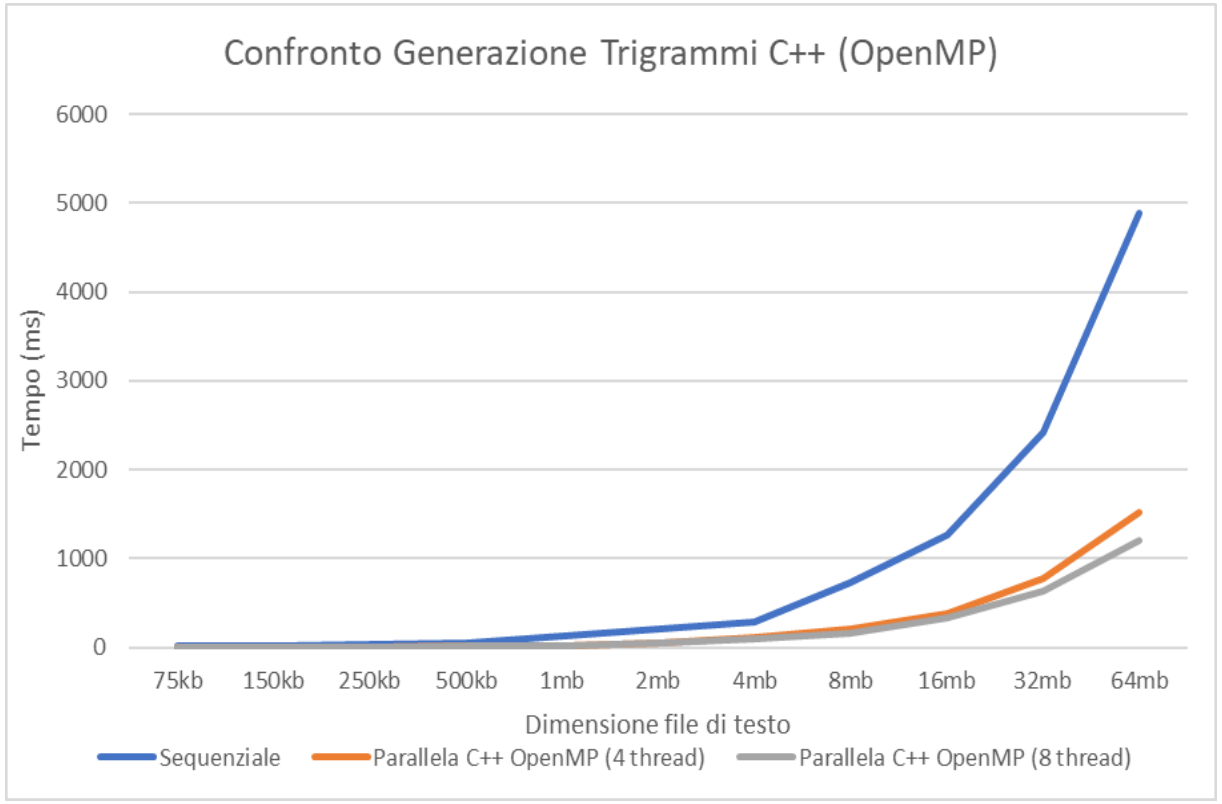

Conclusione

In questo progetto abbiamo:

- Implementato un framework per la generazione di bigrammi e trigrammi
- Sviluppato in una versione sequenziale (Java) e due parallele (Java e C++ OpenMP)
- Effettuato analisi sullo speed up e sulle tempistiche di esecuzione

Grazie dell'attenzione